

# Математическая статистика

## Лекция 1

# Математическая статистика

- **Математическая статистика** — наука, которая разрабатывает математические методы систематизации и применения статистических данных для практических и научных выводов

# План

- Основные понятия
- Точечное оценивание
- Интервальное оценивание
- Тестирование гипотез

# Понятие генеральная совокупности

- Совокупность всех наблюдений случайной величины  $X$ , которые могли бы быть сделаны при данном комплексе условий, называется **генеральной совокупностью** случайной величины  $X$ , или просто *генеральной совокупностью  $X$* .
- Распределение случайной величины  $X$  называется *распределением генеральной совокупности*. Число элементов для конечной генеральной совокупности, называют *объёмом* генеральной совокупности. Генеральная совокупность может быть как конечным, так и бесконечным множеством.

# Понятие случайной выборки

- Совокупность независимых случайных величин  $X_1, \dots, X_n$ , каждая из которых имеет то же распределение, что и наблюдаемая случайная величина  $X$ , называется **случайной выборкой** из генеральной совокупности  $X$ . При этом число  $n$  называют объёмом случайной выборки, а случайные величины  $X_1, \dots, X_n$  – элементами случайной выборки. Любую реализацию  $x_1, x_2, \dots, x_n$  случайной выборки  $X_1, \dots, X_n$  будем называть **выборкой** из генеральной совокупности  $X$ , или выборочной совокупностью. Выборка из генеральной совокупности  $X$  представляет собой некоторое подмножество этой генеральной совокупности.

## Пример

- Пример 1. Эксперимент состоит в подбрасывании правильной игральной кости. Случайная величина  $X$  – число очков, выпавшее на верхней грани, возможные значения случайной величины  $X$ :  $1, \dots, 6$ . В результате эксперимента получаем случайное число  $x$  – реализацию случайной величины  $X$ , . При повторении эксперимента  $n$  раз получаем выборку  $x_1, \dots, x_n$  наблюдений случайной величины  $X$ , или, что то же самое, единственное наблюдение случайной выборки  $X_1, \dots, X_n$  объёма  $n$ . Генеральная совокупность случайной величины  $X$  содержит бесконечное число значений  $1, \dots, 6$  в равных пропорциях.

# Способы формирования выборки

- Полностью случайный отбор
- Простой отбор с помощью регулярной процедуры
- Стратифицированный отбор
- Серийные выборки
- Комбинированный отбор

# Выборочные характеристики

- **1) Вариационный ряд.**

Элементы реализации выборки  $x_1, x_2, \dots, x_n$  упорядочим по возрастанию

$$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n-1)} \leq x_{(n)}$$

где  $x_{(1)} = \min\{x_1, x_2, \dots, x_n\}$ ,  $x_{(n)} = \max\{x_1, x_2, \dots, x_n\}$ .

получится новый набор значений случайных величин, называемый вариационным рядом

Вариационный ряд выборки  $x_1, x_2, \dots, x_n$  можно рассматривать как реализацию вариационного ряда случайной выборки  $X_1, \dots, X_n$ .

Случайную величину  $X_{(k)}$  называется  $k$ -м членом вариационного ряда или  $k$ -й порядковой статистикой.

$X_{(1)}, X_{(n)}$  – экстремальные статистики



# Выборочные характеристики

- **2) Эмпирическая функция распределения.**

- Пусть выборка  $x_1, x_2, \dots, x_n$  объёма  $n$  берется из распределения с функцией распределения  $F(x) = P(X_i \leq x)$ .

Эмпирической функцией распределения, построенной по случайной выборке  $X_1, X_2, \dots, X_n$  объёма  $n$ , называется случайная функция

$$\hat{F}_n(x) = \frac{\text{количество } X_i \in (-\infty, x]}{n} = \frac{\sum_{i=1}^n I(\{X_i \leq x\})}{n}$$

$$\text{где } I(\{X_i \leq x\}) = \begin{cases} 1, & \text{если } X_i \leq x \\ 0, & \text{если } X_i > x \end{cases}$$

# Пример

Пример 1. Пусть дана числовая выборка

$$\vec{X} = (0; 2; 1; 2,6; 3,1; 4,6; 1; 4,6; 6; 2,6; 6; 7; 9; 9; 2,6).$$

Построим по ней вариационный ряд

$$(0; 1; 1; 2; 2,6; 2,6; 2,6; 3,1; 4,6; 4,6; 6; 6; 7; 9; 9)$$

и эмпирическую функцию распределения (рис. 1).




Рис. 1. Эмпирическая функция распределения

Эта функция является функцией распределения случайной величины, принимающей значение 0 с вероятностью  $\frac{1}{15}$ , значение 1 с вероятностью  $\frac{2}{15}$ , значение 2 с вероятностью  $\frac{1}{15}$  и т. д.

# Выборочные характеристики

- **3) Гистограмма** Эмпирическим аналогом таблицы или плотности распределения является гистограмма.
- Гистограмма строится по группированным данным. Предполагаемую область значений случайной величины  $X$  (или область выборочных данных) делят на некоторое количество не обязательно одинаковых интервалов. Пусть  $A_1, \dots, A_k$  — интервалы на прямой, называемые интервалами группировки. Обозначим для  $j = 1, \dots, k$  через  $v_j$  число элементов выборки, попавших в интервал  $A_j$ :

$$v_i = \sum_{i=1}^n I(\{X_i \in A_i\}) - \text{количество } X_i \in A_i$$

$$n = \sum_{j=1}^k v_j$$

На каждом из интервалов  $A_j$  строят прямоугольник, площадь которого пропорциональна  $v_j$ . Общая площадь всех прямоугольников должна равняться единице. Если  $l_j$  — длина интервала  $A_j$ , то высота  $f_j$  прямоугольника над этим интервалом равна

$$\hat{f}_j = \frac{v_j}{n \cdot l_j}$$

Полученная фигура, состоящая из объединения прямоугольников, называется гистограммой.

# Пример

Пример 2. Имеется вариационный ряд из примера 1:

(0; 1; 1; 2; 2,6; 2,6; 2,6; 3,1; 4,6; 4,6; 6; 6; 7; 9; 9).

Разобьём отрезок  $[0, 10]$  на четыре равных отрезка. Отрезку  $[0, 2,5)$  принадлежат четыре элемента выборки, отрезку  $[2,5, 5)$  — шесть, отрезку  $[5, 7,5)$  — три, и отрезку  $[7,5, 10]$  — два элемента выборки. Строим гистограмму (рис. 2). На рис. 3 — гистограмма для той же выборки, но при разбиении области на пять равных отрезков.




Рис. 2. Гистограмма при  $k = 4$




Рис. 3. Гистограмма при  $k = 5$

Чем больше интервалов группировки, тем лучше: фигура, состоящая из более узких прямоугольников, точнее приближает истинную плотность распределения. С другой стороны, бессмысленно брать число интервалов  $k(n)$  порядка  $n$ : тогда в каждый интервал попадёт в среднем по одной точке и гистограмма не будет приближаться к плотности с ростом  $n$ .

# Выборочные характеристики

## 4) Выборочные моменты

Истинные моменты	Оценки
$E(X)=E(X_1)=\mu$	$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$
$D(X)=D(X_1)=\sigma^2$	$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$
$\alpha_k$	$\widehat{\alpha}_k = \frac{1}{n} \sum_{i=1}^n X_i^k$
$\beta_k$	$\widehat{\beta}_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$

# Свойства выборочной функции

Рассмотрим случайную выборку  $X_1, \dots, X_n$  - (независимые одинаково распределенные случайные величины) из распределения  $F$

- 1)  $E(\hat{F}_n(x)) = F(x)$
- 2)  $D(\hat{F}_n(x)) = \frac{1}{n} F(x)(1 - F(x))$
- 3)  $\hat{F}_n(x) \xrightarrow{p} F(x)$ , при  $n \rightarrow \infty$
- Доказательство (см лекцию)
- 4)  $\sup_x |\hat{F}_n(x) - F(x)| \xrightarrow{\text{п.н.}} 0$ , при  $n \rightarrow \infty$

(теорема Гливенко-Кантелли), сильная состоятельность

# Свойства выборочной функции

- 5)  $n\hat{F}_n(x) = \sum_{i=1}^n I(\{x_i \leq x\}) \sim B(n, F(x))$  – биномиальное распределение
- 6)  $\frac{\hat{F}_n(x) - F(x)}{\sqrt{\frac{1}{n}F(x)(1-F(x))}} \xrightarrow[n \rightarrow \infty]{d} z \sim N(0,1)$

Напомним, что по ЦПТ  $\frac{\bar{\xi}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow[n \rightarrow \infty]{d} z \sim N(0,1),$

где  $\bar{\xi}_n = \frac{S_n}{n}, E(\xi_1) = \mu, D(\xi_1) = \sigma^2$

# Свойства выборочного среднего

$X_1, \dots, X_n$  независимые одинаково распределенные случайные величины

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

Пусть  $E(X_1) < \infty$ ,  $E(X_1) = \mu$ ,  $D(X_1) = \sigma^2$

$$1) \quad E(\bar{X}) = E(X_1) = \mu, \quad D(\bar{X}) = \frac{D(X_1)}{n} = \frac{\sigma^2}{n}$$

$$2) \quad \bar{X} \xrightarrow[n \rightarrow \infty]{p} \mu \quad (\text{из ЗБЧ})$$

$$3) \quad \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \xrightarrow[n \rightarrow \infty]{d} z \sim N(0, 1) \quad (\text{из ЦПТ})$$



# Свойства выборочной дисперсии

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$1) \quad E(S^2) \neq \sigma^2, \quad E(S^2) = \frac{n-1}{n} \sigma^2$$

Исправленная выборочная дисперсия (несмещенная оценка)

$$S_0^2 = \frac{n}{n-1} S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$2) \quad S^2 \xrightarrow[n \rightarrow \infty]{p} \sigma^2, \quad S_0^2 \xrightarrow[n \rightarrow \infty]{p} \sigma^2$$

$$3) \quad \frac{S^2 - \sigma^2}{\sqrt{D(S^2)}} \xrightarrow[n \rightarrow \infty]{d} z \sim N(0,1), \quad \frac{S_0^2 - \sigma^2}{\sqrt{D(S_0^2)}} \xrightarrow[n \rightarrow \infty]{d} z \sim N(0,1)$$

# Конечный размер генеральной совокупности

$X_1, X_2, \dots, X_n$  –одинаково распределенные, но не являются независимыми

$$E(X_i) = E(X_1), \text{ т. е. } E(\bar{X}) = E(X_1) = \mu$$

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\underline{\text{УТВ 1.}} \operatorname{cov}(X_i, X_j) = \frac{-\sigma^2}{N-1}$$

Док-во. (смотри лекцию)

$$\underline{\text{УТВ 2.}} D(\bar{X}) = \frac{\sigma^2}{n} \left( 1 - \frac{n-1}{N-1} \right)$$

Док-во. (смотри лекцию)